

공학 석사 학위논문

윈도우 연관성을 활용한 GAN 기반
다변량 시계열 데이터 보정 기법

A GAN-Based Multivariate Time Series Data
Correction Method Using Window Relevance

2025년 02월

서울시립대학교 대학원

전자전기컴퓨터공학과

윤 소 현

윈도우 연관성을 활용한 GAN 기반 다변량 시계열 데이터 보정 기법

A GAN-Based Multivariate Time Series Data
Correction Method Using Window Relevance

지도교수 김 한 준

이 논문을 석사학위 논문으로 제출함

2025년 02월

서울시립대학교 대학원

전 자 전 기 컴 퓨 터 공 학 과

윤 소 현

윤소현의 공학 석사학위 논문을 인준함.

심 사 위 원 장	이승환	인
-----------	-----	---

심 사 위 원	박재휘	인
---------	-----	---

심 사 위 원	김한준	인
---------	-----	---

2024년 12월

서울시립대학교 대학원

국 문 초 록

본 연구에서는 GAN 기반의 이상 탐지 모델을 이용하여 다변량 시계열 데이터의 품질을 개선하는 새로운 데이터 보정 기법을 제안한다. 최근 사물인터넷(IoT) 기술의 발전과 함께 센서를 통해 수집되는 시계열 데이터를 활용하여 딥러닝 기반 모델로 품질 관리 및 예측 정비를 수행하는 사례가 증가하고 있다. 이처럼 시계열 데이터는 제조, 금융, 에너지 등 다양한 산업 분야에서 필수적으로 사용된다. 그러나 데이터 수집 및 처리 과정에서 다양한 요인으로 인해 이상값(anomalies)이 발생할 수 있다. 이러한 문제는 데이터 품질을 저하시킬 뿐만 아니라, 의사결정의 신뢰성을 떨어뜨리는 결과를 초래할 수 있다. 따라서 데이터의 신뢰성과 품질을 확보하여 딥러닝 기반 모델의 성능을 향상시키기 위해 시계열 데이터의 보정은 필수적이다. 우리는 딥러닝 기반의 이상 탐지 모델과 윈도우 연관성 행렬(Window Relevance Matrix)을 결합하여 보정을 수행한다. 제안된 기법은 Autoencoder 기반의 GAN 모델을 활용하여 시계열 데이터 내 이상값을 탐지하고, 다변량 시계열 데이터의 상관관계를 반영하여 보다 정교한 보정을 진행한다. 특히, 동적 시간 워핑(Dynamic Time Warping, DTW)과 피어슨 상관 계수(Pearson correlation)를 결합한 윈도우 연관성 행렬을 생성함으로써 다변량 시계열 데이터의 복잡한 구조를 효과적으로 고려할 수 있다. 이 기법의 유효성을 검증하기 위해 다양한 종류의 데이터를 기반으로 실험을 수행하였으며, 보정된 데이터는 원시 데이터 대비 예측 성능에서 유의미한 향상을 보였다. 본 연구는 데이터 품질 향상을 위해 Autoencoder 기반의 GAN 모델을 이용한 데이터 보정 방법을 제시하며, 이는 이상 탐지 및 데이터 정제를 필요로 하는 다양한 분야에 적용 가능할 것으로 기대된다.

주요어: 다변량 시계열 데이터, 이상 탐지, 데이터 보정, 상관관계, 딥러닝, GAN

공학 석사 학위논문

윈도우 연관성을 활용한 GAN 기반
다변량 시계열 데이터 보정 기법

A GAN-Based Multivariate Time Series Data
Correction Method Using Window Relevance

2025년 02월

서울시립대학교 대학원

전자전기컴퓨터공학과

윤 소 현

목 차

목차	i
그림 차례	iii
표 차례	v
제1장 서론	1
제1절 연구의 배경 및 내용	1
제2절 논문의 구성	3
제2장 관련 연구	4
제1절 이상탐지 연구	4
1. 전통적인 이상탐지	5
2. 딥러닝 기반 이상탐지	7
3. GAN 기반 이상탐지	9
제2절 데이터 보정 연구	12
제3장 제안 기법	14
제1절 다변량 시계열 데이터 보정기법 개요	14
제2절 LSTM 기반 VAE-GAN 모델 학습	17
제3절 이상 탐지	20
제4절 데이터 보정	21
1. 데이터 보정 과정	22
2. 이상치 종류에 따른 보정기법	24
3. Window Relevance Matrix	26
제4장 실험 및 결과	28
제1절 실험 환경	28

제2절 실험 방법	30
제3절 성능 평가	31
제5장 결론	43
참고 문헌	44
Abstract	48

그 립 차 례

그림 2.1.1	시계열 데이터에서의 이상값 발생	4
그림 2.1.2	평균 기반 이상탐지 예시	5
그림 2.1.3	오토인코더 기반 이상탐지 구조	8
그림 2.1.4	GAN 아키텍처	10
그림 3.1.1	제안 보정기법 프로세스	14
그림 3.1.2	제안 보정기법 아키텍처	16
그림 3.2.1	슬라이딩 윈도우 적용 예시	17
그림 3.2.2	LSTM 기반 VAE-GAN 모델 학습 구조	18
그림 3.3.1	이상 탐지 과정	20
그림 3.4.1	탐지된 이상 값에 대한 데이터 보정 과정	21
그림 3.4.2	이상 윈도우를 정상 윈도우로 보정하는 과정	22
그림 3.4.3	제안 보정기법 적용 결과	23
그림 3.4.4	점 이상치에 대한 보정 과정	24
그림 3.4.5	집단 이상치에 대한 보정 과정	25
그림 3.4.6	한 변수에 대한 DTW 정렬 과정 예시	26
그림 3.4.7	피어슨 상관계수 행렬 비교 예시	27
그림 4.2.1	모델 성능으로 인한 간접 평가	30
그림 4.3.1	SWaT에 대한 보정 기법 성능 비교 시각화	33
그림 4.3.2	WADI에 대한 보정 기법 성능 비교 시각화	35
그림 4.3.3	HAI에 대한 보정 기법 성능 비교 시각화	37
그림 4.3.4	SKAB에 대한 보정 기법 성능 비교 시각화	39
그림 4.3.5	SWaT 데이터에 대한 예측모델 잔차 비교	41

그림 4.3.6 WADI 데이터에 대한 예측모델 잔차 비교	41
그림 4.3.7 HAI 데이터에 대한 예측모델 잔차 비교	42
그림 4.3.8 SKAB 데이터에 대한 예측모델 잔차 비교	42

표 차 례

표 4.1.1 실험 데이터 정보	29
표 4.3.1 SWaT 데이터에 대한 보정 기법 성능 비교	32
표 4.3.2 WADI 데이터에 대한 보정 기법 성능 비교	34
표 4.3.3 HAI 데이터에 대한 보정 기법 성능 비교	36
표 4.3.4 SKAB 데이터에 대한 보정 기법 성능 비교	38
표 4.3.5 Window Relevance 임계값에 따른 성능 비교	40

제 1장 서 론

제1절 연구의 배경 및 내용

사물인터넷(Internet of Things, IoT) 기술이 발전함에 따라 스마트 팩토리, 스마트 시티, 금융, 에너지 등 다양한 산업 분야에서 데이터의 수집과 분석이 활발히 이루어지고 있다[10, 20]. 이러한 IoT 기술은 네트워크로 연결된 센서를 통해 대규모 데이터를 실시간으로 수집하며[6], 이를 활용해 시스템 상태를 모니터링[30]하고 이상 현상을 감지하며, 예측 정비 및 사고 대응을 가능하게 한다. 이 과정에서 수집된 데이터는 시간의 흐름에 따라 연속적으로 기록된 시계열 데이터(Time Series Data)로, 특정 시스템이나 환경의 상태를 나타낸다. 예를 들어, 제조업에서는 설비의 온도, 습도, 압력 등의 데이터를 분석하여 성능 최적화와 고장 예방을 위한 예측 모델을 구축하는 데 활용하고 있다[15, 17, 23].

하지만 시계열 데이터는 수집 과정에서 발생하는 다양한 요인으로 인해 이상값(anomalies)을 포함할 수 있다[16]. 이상값은 정상적인 데이터 패턴에서 벗어난 비정상적인 값으로, 센서 오작동이나 데이터 전송 오류, 환경적 요인 등으로 인해 발생한다. 예를 들어, 온도를 측정하는 센서가 일시적으로 오작동하여 비현실적으로 높은 값을 기록하거나, 네트워크 장애로 인해 데이터가 불완전하게 저장되는 경우가 있다[4]. 이러한 이상값은 데이터의 신뢰성을 저하시킬 뿐만 아니라, 학습 데이터에 포함되어 있을 경우 예측 모델 성능에도 부정적인 영향을 미친다. 따라서 예측 모델의 성능과 신뢰성을 확보하기 위해서는 시계열 데이터의 이상값을 탐지하고 보정하는 과정이 반드시 필요하다[27, 31].

특히 다변량 시계열 데이터는 여러 변수 간의 상호작용을 포함하고 있어, 단변량 데이터에 비해 훨씬 더 복잡한 특성을 가진다[28]. 따라서 다변량 데이터를 효과적으로 보정하려면 변수들 간의 관계와 시간적 특성을 모두 고려해야 한다. 기존의 이상값 탐지 및 보정 방법은 주로 단변량 데이터에 초점이 맞추어져 있거나 변수들 간의 상호작용을 충분히 반영하지 못하는 경우가 많았다.

본 연구에서는 LSTM(Long Short-Term Memory) 기반의 VAE-GAN(Variational AutoEncoder Generative Adversarial Networks) 모델[26]과 시간적 특성을 고려한 Window Relevance Matrix를 결합하여 다변량 시계열 데이터의 이상값을 탐지하고

보정하는 기법을 제안한다. 제안된 기법은 DTW(Dynamic Time Warping)와 피어슨 상관 계수(Pearson correlation)를 기반으로 윈도우 연관성 행렬(Window Relevance Matrix)을 구성하여 변수들 간의 복잡한 상호작용을 효과적으로 반영한다. 이를 통해 이상값 탐지뿐만 아니라 데이터 간의 연관성을 고려한 보정을 수행함으로써 데이터 품질을 개선하고 딥러닝 기반 예측 모델의 성능을 향상시킬 수 있다.

제안된 기법의 유효성을 검증하기 위해 SWaT(Secure Water Treatment)[24], WADI(Water Distribution)[1], HAI(HIL-based Augmented ICS)[13], 그리고 SKAB(Skoltech Anomaly Benchmark)과 같은 공공 데이터셋을 이용하여 실험을 수행하였다. 실험 결과, 제안된 기법은 원시 데이터 대비 예측 성능에서 유의미한 향상을 보였으며, 이는 다양한 산업 환경에서 데이터 품질 향상과 모델 신뢰성 확보에 기여할 수 있음을 입증하였다.

제2절 논문의 구성

본 논문은 다음과 같은 구성으로 진행된다. 2장에서는 이상탐지 및 보정 연구에 대해서 소개한다. 기존의 이상탐지 방법과 실험에서 사용한 생성 모델에 대한 개념 및 생성모델 기반 이상탐지 과정에 대해 설명한다. 그리고 데이터 보정 연구의 동향에 대해 정리한다.

3장에서는 Window Relevance Matrix를 활용한 제안된 다변량 시계열 데이터 보정기법에 대해 서술한다.

4장에서는 실험에 사용한 데이터셋에 대해 정리하고 성능을 평가 방법을 설명한다. 제안 기법을 적용하여 데이터를 보정하고 이를 활용해 예측 모델을 구축한다. 예측모델의 성능을 기존 보정 기법과 비교하여 제안 기법의 우수성을 입증한다.

마지막으로, 5장에서는 본 논문의 주요 내용을 요약하고 향후 연구 방향을 제시하며 결론을 맺는다.

제 2장 관련 연구

제1절 이상탐지 연구




그림 2.1.1 시계열 데이터에서의 이상값 발생

시계열 데이터에서의 이상값(anomaly)은 정상적인 데이터 패턴에서 벗어난 값으로 정의된다. 이상값의 종류에는 점 이상값(Point Anomaly)과 집단 이상값(Collective Anomaly)이 포함되며[33], 점 이상값은 단일 데이터 포인트가 정상 패턴에서 벗어난 경우를, 집단 이상값은 연속된 데이터 구간에서 관찰되는 비정상적인 패턴을 의미한다. 그림 2.1.1은 시계열 데이터에서 점 이상값과 집단 이상값의 예를 시각적으로 나타낸다.

이러한 이상값은 데이터 품질을 저하시켜 예측 모델의 신뢰성을 저하시키는 주요 원인이 된다. 초기에는 평균과 분산 등의 통계적 방법을 사용하여 이상값을 탐지했으나, 데이터 복잡성이 증가하면서 한계를 드러냈다. 이에 따라 기계학습 기반 접근법이 등장하며, 이상탐지의 정밀성을 높이기 위한 다양한 기법들이 제안되었다. 이상탐지 연구는 단순히 이상값의 존재를 확인하는 데 그치지 않고, 시스템에 미치는 영향을 분석하거나 발생 원인을 설명하며, 이상값을 정상값으로 보정하는 방향으로 발전하고 있다[12].

1. 전통적인 이상탐지

이상탐지는 데이터의 품질을 보장하고 분석 및 예측 모델의 신뢰성을 높이기 위해 필수적인 과정이다[37]. 전통적인 이상탐지 방법은 데이터의 특성과 접근 방식에 따라 크게 통계적 방법, 거리 기반 방법, 밀도 기반 방법, 신호 처리 기법, 모델 기반 방법으로 분류된다.




그림 2.1.2 평균 기반 이상탐지 예시

(1) **통계적 방법:** 이상탐지의 가장 초기 형태로, 데이터 분포를 기반으로 평균과 분산을 활용해 정상 범위를 정의하고, 이 범위를 벗어난 값을 이상값으로 간주한다[14]. 그림 2.1.2는 평균 기반 이상탐지의 예를 시각적으로 나타낸 것이다. 평균으로부터 3σ 이상 벗어난 값을 이상값으로 판단하고 있다. 이러한 방식은 계산이 간단하고 직관적이며 소규모 데이터에서 효과적이다. 하지만 데이터가 비정규 분포를 따르거나 다변량 데이터일 경우 성능이 크게 저하되는 한계를 가진다.

(2) **거리 기반 방법:** 데이터 포인트 간의 거리를 계산하여 이상값을 탐지한다. K-최근접 이웃(K-Nearest Neighbors, KNN) 알고리즘은 데이터가 인접한 이웃들과의 평균 거리가 임계값을 초과하면 이상값으로 판단한다[29].

(3) **밀도 기반 방법:** 데이터 포인트가 위치한 영역의 밀도를 측정하고, 밀도가 낮은 데이터를 이상값으로 간주한다. 대표적으로 DBSCAN(Density-Based Spatial

Clustering of Applications with Noise)은 군집화 과정에서 밀도가 낮은 점을 이상값으로 탐지한다[9]. 이러한 방법들은 다양한 데이터셋에 적용 가능하지만, 데이터 차원이 증가할수록 계산 비용이 급격히 증가하는 차원의 저주(Curse of Dimensionality) 문제에 취약하다.

(4) **신호 처리 기법:** 주로 시계열 데이터의 이상탐지에 사용되며, 데이터의 시간적 패턴과 주파수 특성을 분석하는 데 초점을 맞춘다. 이동평균(Moving Average) 방법은 일정 구간의 평균값과 관측값을 비교하여 이상값을 탐지하며[25], 웨이블릿 변환(Wavelet Transform)은 신호를 주파수 영역으로 변환하여 특정 주파수 대역에서 발생하는 이상값을 탐지한다[22]. 이러한 기법은 시계열 데이터의 시간적 연속성을 반영할 수 있는 장점이 있으나, 데이터의 복잡성이 증가하면 이상값 탐지 성능이 저하될 수 있다.

(5) **모델 기반 방법:** 데이터의 구조를 모델링하여 예상값과 관측값의 차이를 활용해 이상값을 탐지하는 방식이다. ARIMA와 같은 시계열 모델은 데이터의 패턴을 학습하고 예상값과의 오차를 분석해 이상값을 판단한다[35]. 또한, 칼만 필터(Kalman Filter)는 상태 공간 모델을 통해 현재 상태를 예측하고 잔차(Residual)를 계산하여 이상값을 탐지[18]한다.

전통적인 이상탐지 방법들은 데이터의 시간적 특성을 반영할 수 있지만, 모델의 복잡도 증가로 인해 제한적인 적용 범위를 가진다. 이러한 한계를 극복하기 위해 딥러닝 기반 이상탐지가 주목받고 있다. 딥러닝 모델은 비선형적이고 복잡한 데이터 구조를 학습할 수 있으며, 다변량 데이터 간의 상관관계를 효과적으로 반영한다. 따라서 본 연구는 딥러닝 기반 접근법을 활용하여 전통적인 이상탐지 방법의 한계를 해결할 수 있는 이상탐지를 수행한다.

2. 딥러닝 기반 이상탐지

전통적인 이상탐지 방법은 계산이 간단하고 직관적인 장점이 있는 반면, 데이터 복잡성이 증가하거나 다변량 데이터에 대해서는 한계를 드러낸다. 이러한 한계를 극복하기 위해 딥러닝 기반 이상탐지가 주목받고 있다. 딥러닝 모델은 복잡한 데이터 패턴을 학습하고 변수 간의 상호작용을 효과적으로 반영할 수 있다[19]. 따라서 최근에는 LSTM, Autoencoder, GAN, GNN 구조를 이용한 이상탐지 방법에 대한 연구가 많이 진행되고 있다.

(1) **LSTM(Long Short-Term Memory)**: 순환신경망(RNN)의 확장 모델로, 시계열 데이터의 장기적 의존성을 학습하는 데 최적화되어 있다. LSTM은 정상적인 데이터 패턴을 학습한 후, 입력 데이터와 예측 값 간의 차이(오차)를 분석하여 이상값을 탐지한다[8]. 이는 시간적 연속성이 중요한 시계열 데이터에서 뛰어난 성능을 발휘한다.

(2) **오토인코더(Autoencoder)**: 입력 데이터를 압축한 후 복원하는 비지도 학습 모델로, 그림 2.1.3에서와 같이 정상 데이터만을 학습하여 재구성 오차(Reconstruction Error)를 활용해 이상값을 탐지한다[5]. 입력 데이터는 인코더(Encoder)를 통해 잠재 변수(Latent Variable)로 압축된 후, 디코더(Decoder)를 통해 복원된 데이터로 재구성된다. 이 과정에서 정상 데이터는 입력과 복원 데이터 간의 차이(Difference)가 작지만, 이상값은 입력 데이터와 복원된 데이터 간의 차이가 크다는 특성을 기반으로 이상탐지가 이루어진다. 이러한 구조는 단변량 및 다변량 데이터 모두에 적용 가능하며, 특히 시계열 데이터의 시간적 특성을 반영하는 데 효과적이다.

(3) **GAN(Generative Adversarial Network)**: 생성자(Generator)와 판별자(Discriminator)가 경쟁적으로 학습하며 정상 데이터의 분포를 모델링하는 비지도 학습 기법이다. 생성자는 실제 데이터와 유사한 데이터를 생성하고, 판별자는 입력 데이터가 실제 데이터인지 생성된 데이터인지를 구분한다. 이 과정에서 정상 데이터의 분포를 학습한 판별자는 입력 데이터가 정상 분포에서

벗어난 경우 이를 이상값으로 간주한다[34].

(4) **GNN(Graph Neural Network)**: 데이터 간의 관계를 그래프 구조로 모델링하여 노드(Node)와 엣지(Edge) 수준에서 이상값을 탐지한다. 특히, 네트워크 형태의 데이터에서 특정 노드 또는 서브그래프가 정상적인 관계 패턴에서 벗어난 경우 이를 이상값으로 탐지한다[7]. GNN은 관계형 데이터 분석에서 좋은 성능을 보인다.




그림 2.1.3 오토인코더 기반 이상탐지 구조

딥러닝 기반 이상탐지 방법은 데이터의 복잡한 패턴을 자동으로 학습하고, 고차원 데이터와 비선형적 구조를 효과적으로 처리할 수 있는 장점이 있다. 이에 따라 본 연구에서는 생성모델인 GAN 기반으로 이상탐지를 수행한다.

3. GAN 기반 이상탐지

본 연구에서는 LSTM, VAE(Variational AutoEncoder), 그리고 GAN을 결합한 VAE-GAN 모델을 활용하여 이상탐지를 수행한다. 이를 위해 생성모델인 GAN의 작동 원리와 이를 기반으로 한 이상탐지 방법에 대한 이해가 필수적이다.

1) GAN

생성자(Generator)와 판별자(Discriminator)라는 두 개의 신경망이 적대적으로 학습하며 데이터 분포를 모델링하는 비지도 학습 기법이다[11]. 생성자는 랜덤 노이즈 벡터 z 를 입력으로 받아 실제 데이터와 유사한 데이터를 생성하고, 판별자는 입력 데이터가 실제 데이터인지 생성된 데이터인지 구분하는 역할을 한다. 이 두 네트워크는 상호작용하며 학습을 진행하며, 생성자는 점차 실제 데이터 분포를 근사하는 능력을, 판별자는 생성된 데이터와 실제 데이터를 구분하는 능력을 갖추게 된다. GAN의 목적 함수는 다음과 같이 정의된다:

$$\min_G \max_D V(D, G) = E_{x \sim p_{data}(x)} [\log D(x)] + E_{z \sim p_z(z)} [\log(1 - D(G(z)))] \quad (2.1.1)$$

식 2.1.1에서 $D(x)$ 는 판별자가 입력 데이터 x 가 실제 데이터일 확률을 출력하는 함수이며, $G(z)$ 는 생성자가 랜덤 노이즈 z 를 입력으로 받아 생성한 데이터를 의미한다. $p_{data}(x)$ 는 실제 데이터의 분포를, $p_z(z)$ 는 랜덤 노이즈의 분포를 나타낸다. 판별자는 $V(G, D)$ 값을 최대화하려 하고 생성자는 최소화하려 한다. GAN의 학습이 수렴하면, 판별자는 생성된 데이터와 실제 데이터를 구분하지 못하게 되고, 생성자는 실제 데이터와 거의 동일한 품질의 데이터를 생성할 수 있다.

그림 2.1.4는 GAN의 구조를 시각적으로 나타낸다. 생성자는 랜덤 노이즈 z 를 입력으로 받아 Fake 데이터를 생성하며, 판별자는 Fake와 Real 데이터를 입력받아 이를 구분한다. 생성자와 판별자의 적대적 학습을 통해 GAN은 실제 데이터 분포를 근사하게 되고, 이를 바탕으로 이상탐지 분야와 같이 다양한 응용에서 좋은 성능을 발휘할 수 있다.




그림 2.1.4 GAN 아키텍처

2) GAN 기반 이상탐지

GAN을 이용한 이상탐지는 정상 데이터의 분포를 학습하여 입력 데이터가 정상 데이터 분포와 얼마나 다른지를 평가하는 방식으로 이루어진다. 이상탐지에서는 주로 재구성 기반 접근과 판별 기반 접근이라는 두 가지 방법이 활용된다.

재구성 기반 접근에서는 정상 데이터만을 사용하여 모델을 학습시킨 후, 입력 데이터를 생성자를 통해 재구성한다. 생성자는 학습된 정상 데이터 분포를 바탕으로 입력 데이터를 복원하려 시도하며, 이 과정에서 입력 데이터와 재구성된 데이터 간의 차이인 재구성 오차(Reconstruction Error)를 계산하여 이상값을 탐지한다. 정상 데이터는 재구성 오차가 작지만, 이상값은 정상 데이터 분포에서 벗어나 있으므로 재구성 오차가 크게 나타난다. 재구성 오차가 설정된 임계값(Threshold)을 초과하면 해당 데이터를 이상값으로 판단한다.

판별 기반 접근에서는 판별자를 활용하여 입력 데이터가 정상 데이터 분포에 속하는지 여부를 평가한다. GAN 학습 과정에서 판별자는 생성 데이터와 실제 데이터를 구분하는 능력을 학습하므로, 학습된 판별자의 출력을 분석하여 이상값 여부를 판단할 수 있다. 판별자의 출력 값이 낮으면 입력 데이터가 정상 데이터 분포에서 벗어난 것으로 간주된다.

GAN 기반 이상탐지는 정상 데이터의 복잡한 분포를 비선형적으로 모델링할 수

있어 기존의 통계 기반 이상탐지 방법에 비해 높은 정밀도를 제공한다. 또한, 다변량 데이터 및 비정형 데이터와 같은 복잡한 데이터셋에서도 높은 성능을 발휘한다. 하지만 GAN 기반 이상탐지는 학습 과정에서 모드 붕괴(Mode Collapse)와 같은 문제가 발생할 수 있다. 이는 생성자가 정상 데이터의 일부 패턴만을 학습하게 되는 현상으로, 이상탐지의 신뢰성을 저하시킬 수 있다. 이러한 문제를 해결하기 위해 최근에는 VAE-GAN과 같이 확장된 모델이 제안되고 있다. 이러한 모델은 정상 데이터의 분포를 보다 정확히 모델링함으로써 이상탐지 성능을 향상시킨다.

따라서 본 연구에서는 다변량 시계열 데이터에서의 이상탐지에 VAE-GAN 모델을 적용하여 정밀한 탐지 성능을 달성하고자 한다.

제2절 데이터 보정 연구

시계열 데이터 내 탐지된 이상값을 정상값으로 보정하는 연구는 이상탐지 관련 연구 대비 활발하지 않다. 그러나 이상값은 데이터의 신뢰성을 저하시킬 수 있으므로 시계열 데이터의 이상값 보정 연구는 데이터 분석 및 예측 모델의 정확성을 확보하는데 필수적이다. 전통적인 통계적 방법부터 딥러닝 기반 방법 등 다양한 접근 방식이 있다.

(1) **평균 및 중앙값 기반 보정:** 평균(mean) 또는 중앙값(median)을 이용한 보정은 이상값이 탐지된 지점을 주변 데이터의 평균이나 중앙값으로 대체하는 방식이다[2]. 이 방법은 계산이 간단하고 소규모 데이터에서 효과적이지만, 이상값이 발생한 위치의 데이터 패턴을 고려하지 않기 때문에 복잡한 데이터에서는 보정 성능이 제한적이다. 예를 들어, 이동평균(Moving Average)은 주어진 윈도우 내의 값을 평균하여 이상값을 완화하는 데 활용될 수 있다[32].

(2) **이상값 제거 기반 보정:** 탐지된 이상값을 데이터셋에서 완전히 제거하거나 무시하는 접근 방식이다. 이러한 방법은 이상값이 데이터 분석에 미치는 영향을 줄일 수 있지만, 데이터의 시간적 연속성과 패턴을 고려하지 않아 중요한 정보를 손실할 위험이 있다. 특히 이상값의 비율이 많은 데이터의 경우 이상값을 제거하면 성능이 저하될 수 있다.

(3) **SVR(Support Vector Regression) 기반 보정:** 이상값을 보정하기 위해 활용되는 머신러닝 기법 중 하나로, 데이터의 이상값 탐지와 보정을 동시에 수행할 수 있다. 정상 데이터로 학습된 SVR 모델은 이상값이 포함된 데이터 포인트를 예측 값으로 대체하여 보정한다 [21]. 이는 비선형 데이터 패턴을 처리할 수 있는 장점이 있으나, 고차원 데이터나 다변량 데이터의 경우 성능이 제한적일 수 있다.

(4) **딥러닝 기반 보정:** 최근에는 딥러닝 모델을 적용하여 시계열 데이터의 이상값을 보정하는 연구들이 증가하고 있다. 시계열 데이터에는 주로 순환신경망이 활용되며 특히 LSTM이 많이 사용된다. LSTM은 시계열 데이터의 시간적 연속성과

의존성을 모델링하여 이상값 주변의 정상 데이터를 학습하고, 이를 기반으로 이상값을 보정한다[3].

또한, 오토인코더는 입력 데이터를 압축하고 복원하는 과정에서 정상 데이터의 패턴을 학습하여 보정 데이터 생성에 활용된다[36]. 오토인코더는 정상 데이터에 대해 학습한 뒤, 이상값이 포함된 데이터를 입력받아 복원된 데이터와의 재구성 오차를 최소화함으로써 이상값을 보정한다. 이러한 오토인코더 기반 접근은 시계열 데이터뿐만 아니라 다변량 데이터에도 적용 가능하며, 정상 데이터의 구조를 유지하면서 보정을 수행할 수 있는 장점이 있다.

LSTM과 오토인코더는 각각의 장점을 바탕으로 시계열 데이터의 복잡한 패턴을 학습하며, 이를 결합하거나 확장한 딥러닝 모델은 정교한 이상값 보정을 가능하게 한다.

본 연구에서는 기존의 데이터 보정기법보다 우수한 성능의 보정기법을 제안하기 위해 LSTM 기반 VAE-GAN 모델을 이용하여 다변량 시계열 데이터의 시간적 특성을 고려할 수 있는 방법을 제안한다.

제 3장 제안 기법

제1절 다변량 시계열 데이터 보정 기법 개요

그림 3.1.1은 본 논문이 제안하는 데이터 보정 기법의 프로세스를 보여준다. 본 연구에서는 VAE-GAN 모델을 활용하여 다변량 시계열 데이터의 이상탐지와 데이터 보정을 수행한다. 제안 기법은 크게 두 가지 주요 단계로 구성된다.




그림 3.1.1 제안 보정기법 프로세스

(1) 이상 탐지(Anomaly Detection)

다변량 시계열 데이터 내에 존재하는 이상값을 보정하기 위해서 이상값 탐지를 진행한다. 본 논문은 기존 다변량 시계열 데이터에 대한 이상탐지 연구를 참고하여 LSTM 기반 VAE-GAN 모델로 이상탐지를 수행한다. VAE-GAN 모델을 학습 데이터로 훈련하여 정상 패턴을 학습하고 훈련된 모델을 통해 테스트 데이터에서 이상 패턴을 탐지한다. 이는 정상 데이터와 이상 데이터 간의 분포 차이를 기반으로 이상값을 식별하는 단계이다.

(2) 데이터 보정(Data Correction)

탐지된 이상 윈도우를 보정하기 위해 우리는 연관성 행렬(Window Relevance Matrix)을 생성한다. 이는 이상값을 보정하기에 가장 좋은 정보를 담고 있는 윈도우들을 찾기 위해 고안되었다. 연관성 행렬에는 시간적 특성과 변수간의 관계를 고려하는 계산이 적용된다. 연관성이 높은 윈도우들의 정보를 이용하여 학습된 VAE-GAN 모델의 생성자로 정상값과 유사한 윈도우를 재생성한다. 생성된 윈도우로 탐지된 이상 윈도우를 보정함으로써 최종적으로 보정된 테스트 데이터가 나오게 된다.

그림 3.1.2는 제안 보정 기법 프로세스를 구체적으로 보여주는 아키텍처이다. VAE-GAN 모델을 학습하는 Model Training 단계와 이 학습된 Encoder, Generator, Discriminator를 이용하여 이상값을 탐지하는 Anomaly detection, 그리고 이상값에 대해 정상값으로 보정하는 Anomaly correction 파트로 나누어져 있다.




그림 3.1.2 제안 보정기법 아키텍처

제2절 LSTM 기반 VAE-GAN 모델 학습

본 논문에서는 다변량 시계열 데이터의 이상 탐지와 보정을 위해 기존에 제안된 LSTM 기반 VAE-GAN 모델[26]을 적용하고 학습하였다. VAE-GAN은 정상 데이터의 분포를 학습하여 이를 기반으로 이상 데이터를 탐지하고 정상 분포에 가까운 데이터로 보정할 수 있도록 설계된 모델이다. VAE와 GAN의 구조를 결합한 VAE-GAN 모델은 Encoder, Generator, Discriminator로 구성되며, 특히 LSTM을 활용하여 시계열 데이터의 시간적 의존성을 효과적으로 반영한다. 학습 과정은 다음과 같이 구성된다.

(1) 슬라이딩 윈도우(Sliding Window)

입력 데이터를 모델에 적합한 형태로 변환하기 위해 슬라이딩 윈도우 기법을 사용하였다. 주어진 시계열 데이터에서 슬라이딩 윈도우 크기와 스텝 크기(step size)를 기준으로 각 윈도우가 정의된다. 그림 3.2.1는 다변량 시계열 데이터에 슬라이딩 윈도우 기법을 적용하여 세분화된 윈도우로 분할하는 예시를 보여준다. 그림에서는 온도, 습도, 압력이라는 세 변수를 가지고 있는 다변량 시계열 데이터이며 7개의 시점(time stamp)으로 구성되어있다. 이때 윈도우의 크기를 3으로 설정하고, 스텝 크기를 1로 설정하였을 때 슬라이딩 윈도우를 적용한 예시이다. 이러한 방법으로 세분화된 각 윈도우들은 LSTM 기반 Encoder의 입력으로 사용된다.




그림 3.2.1 슬라이딩 윈도우 적용 예시

(2) VAE-GAN 모델 학습

슬라이딩 윈도우를 통해 생성된 각 윈도우들은 LSTM 기반의 Encoder의 입력으로 사용된다. Encoder는 입력 데이터를 잠재 공간(latent space) 벡터 Z 로 변환하며, 평균과 표준편차를 계산하여 벡터가 정규화된 분포를 따르도록 학습한다.

생성자는 인코더에서 생성된 잠재 공간 벡터 Z 를 입력받아 데이터를 재구성($\tilde{X}$)하거나, 정규분포에서 샘플링된 벡터 $Z \sim N(0, I)$ 를 통해 새로운 데이터($\hat{X}$)를 생성한다. 그리고 재구성된 데이터와 생성된 데이터를 판별자가 가짜로 분류하지 못하도록 학습한다.

판별자는 실제 데이터(X)를 진짜로, 재구성 및 생성 데이터를 가짜로 잘 구분할 수 있도록 학습한다. 그림 3.2.2는 LSTM 기반 VAE-GAN 모델의 구조를 보여준다.




그림 3.2.2 LSTM 기반 VAE-GAN 모델 학습 구조

LSTM 기반 VAE-GAN 모델의 학습을 위한 인코더와 생성자 그리고 판별자의 손실함수는 다음과 같다.

$$L_{Encoder} = L_{kl} + L_{re}, \quad (3.2.1)$$

$$L_{kl} = KL(q(z|x)||p(z)), \quad (3.2.2)$$

$$L_{re} = -E_{q(z|x)}[\log(p(Dis'(x)|z))], \quad (3.2.3)$$

$$L_{Generator} = -\log(Dis(\hat{x})) - \log(Dis(\tilde{x})) + L_{re}, \quad (3.2.4)$$

$$L_{Discriminator} = -\log(1 - Dis(\hat{x})) - \log(1 - Dis(\tilde{x})) - \log(1 - Dis(x)) \quad (3.2.5)$$

첫 번째로, 인코더는 입력 데이터를 잠재 공간으로 변환하고 이 공간이 정규분포를 따르도록 KL 발산(Kullback-Leibler divergence) 손실(식 3.2.2)을 최소화한다. 동시에 생성자가 생성한 값과 실제 값의 차이인 재구성 손실(식 3.2.3)을 최소화한다. 이러한 손실을 통합한 인코더의 전체 손실 함수는 식 3.2.1로 정의되며, 이를 통해 모델은 데이터의 주요 특징을 유지하면서 정상 데이터 분포를 안정적으로 학습한다.

두 번째로, 생성자는 데이터를 재구성하거나 생성하여 판별자가 이를 진짜로 분류하도록 학습되며, 이 과정은 식 3.2.4로 정의된다. 여기서 재구성 손실(식 3.2.3)을 포함하여 입력 데이터와 유사한 데이터를 생성하는 데 초점을 맞춘다.

마지막으로 실제 데이터는 진짜로, 재구성 및 생성 데이터는 가짜로 분류하도록 학습되며, 손실 함수는 식 3.2.5로 정의된다. 본 논문에서는 이상탐지 및 보정을 위해 이상값이 없는 정상 윈도우만을 가지는 학습 데이터로 모델을 학습하였다.

제3절 이상 탐지

학습된 모델을 이용하여 이상값이 포함되어 있는 테스트 데이터에 대해 이상탐지를 수행한다. 그림 3.3.1은 학습된 VAE-GAN 모델을 이용한 이상 탐지 과정을 담은 그림이다.




그림 3.3.1 이상 탐지 과정

여기서, 학습된 생성자(Trained Generator)가 생성한 가짜 윈도우($\hat{X}$)와 실제 윈도우(X) 사이의 재구성 오차(Reconstruction difference)와 해당 윈도우에 대한 판별자(Trained Discriminator)의 판별 결과(Discrimination results)를 함께 사용하여 이상 점수(Anomaly Score)를 계산한다. 이상 점수는 식 3.3.1과 같이 정의되며 이상 점수가 일정 임계값(t_1) 이상인 경우 해당 윈도우를 이상($x_{anomaly}$)으로 탐지한다.

$$AnomalyScore = (1 - \alpha) |X_{test} - \hat{X}_{test}| + \alpha Dis(X_{test}) \quad (3.3.1)$$

예를 들어 실제 윈도우에 이상값이 포함될 경우, 생성자가 생성한 윈도우와 실제 윈도우의 차이인 재구성 오차와 판별자에 의한 판별 결과는 커지게 되어 이상 스코어가 높아진다. 그 결과, 해당 윈도우를 이상 윈도우로 탐지하게 된다.

제4절 데이터 보정

LSTM 기반 VAE-GAN 모델은 정상 윈도우가 인코더를 통해 생성자로 전달되면 정상 윈도우와 유사한 윈도우를 생성하고 판별자로 실제 윈도우를 판별하도록 학습되었다.

본 논문에서는 생성자가 정상 윈도우와 유사한 윈도우를 생성하는 특성을 이용하여 탐지된 이상 윈도우에 대한 보정을 수행한다. 그림 3.4.1은 학습된 인코더와 생성자를 이용한 보정 과정을 나타내는 그림이다. 이때, 보정 과정에서 더 많은 윈도우의 정보를 담기 위해 연관성 행렬(Window Relevance Matrix)을 생성한다. 연관성 행렬에는 시간적 특성과 변수간의 관계를 고려하는 계산이 적용되며 연관성이 높은 윈도우들의 정보를 이용하여 학습된 VAE-GAN 모델의 생성자로 정상값과 유사한 윈도우를 재생성한다. 최종적으로 데이터 보정은 생성된 정상 윈도우로 탐지된 이상 윈도우를 대체하는 방식이다.

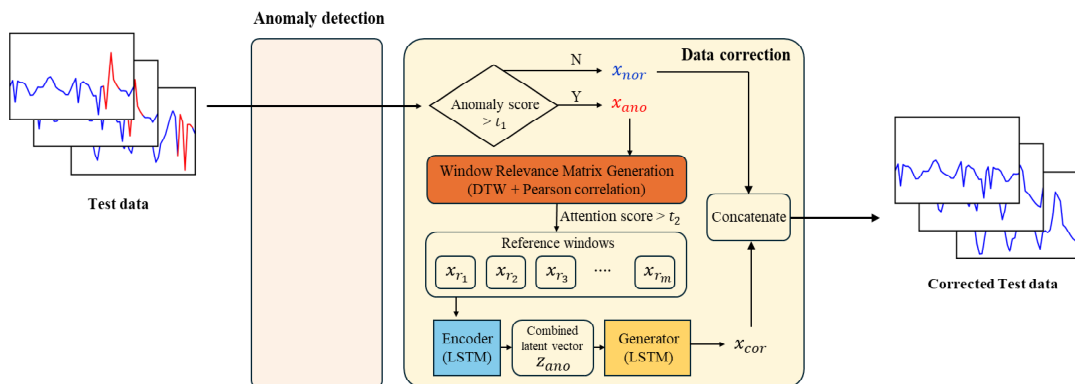


그림 3.4.1 탐지된 이상 값에 대한 데이터 보정 과정

1. 데이터 보정 과정

‘이상’ 으로 탐지된 윈도우를 ‘정상’ 윈도우로 보정하기 위해서 우리는 학습된 인코더와 생성자를 이용한다. 그림 3.4.2는 탐지된 이상 윈도우를 정상 윈도우로 보정하는 과정이다. 이상 윈도우(x_{ano})가 탐지되었다고 할 때, 정상 윈도우로 보정하는 과정은 다음과 같다.




그림 3.4.2 이상 윈도우를 정상 윈도우로 보정하는 과정

첫 번째 단계로는 이상 윈도우를 대체할 수 있는 정보를 담고 있는 윈도우를 탐색하는 것이 수행되어야 한다. 우리는 이상 윈도우와 가장 근접한 윈도우들이 이상 윈도우와 유사한 패턴을 공유하므로, 높은 연관성을 가진 윈도우로 간주하였다. 따라서 이 윈도우들(x_{s_2}, x_{s_3})은 연관성이 높은 다른 윈도우들을 탐색하기 위한 기준 윈도우(Target window)로 정의된다.

두 번째로, 이상 윈도우를 제외한 모든 윈도우들을 Search window로 정의하고 이에 대해 Window Relevance matrix를 생성한다. 윈도우 연관성(Window Relevance)은 윈도우 간의 유사도를 기반으로 생성되며 시간적 특성을 고려하기 위한 DTW 유사도와 변수간의 관계를 고려하기 위한 피어슨 상관계수를 결합하여 구성한다. 자세한 Window Relevance matrix 생성방법은 뒤에서 다룬다.

세 번째로, 우리는 연관성이 높은 윈도우들의 정보를 추출하기 위해 Window Relevance가 임계값(t_2) 이상인 윈도우들을 참조 윈도우(Reference window)로 정의한다. 그림의 예시에서 윈도우 연관성이 임계값 이상인 윈도우가 x_{s_1}, x_{s_4} 라고 가정했을 때 가장 연관성이 높은 기준 윈도우를 포함한 $x_{s_1}, x_{s_2}, x_{s_3}, x_{s_4}$ 윈도우들이 참조 윈도우가 된다.

네번째 단계로, 참조 윈도우들을 학습된 인코더의 입력값으로 넣는다. 그리고 인코더의 출력 값인 잠재벡터들을 결합하여 하나의 결합된 잠재벡터(combined latent vector)를 생성(x_{ano})한다. 우리는 여러 윈도우들의 정보를 결합함으로써 시계열 데이터 내의 다양한 패턴을 반영하였으며 보정에 대한 품질 향상을 기대한다.

마지막으로 결합된 잠재벡터를 학습된 생성자에 넣어 새로운 정상값(x_{cor})을 생성한다. 이를 가지고 이상 윈도우를 대체함으로써 보정하면 최종적으로 정상적인 패턴을 가지는 보정된 데이터가 나오게 된다.




그림 3.4.3 제안 보정기법 적용 결과

그림 3.4.3는 실험 데이터 중 HAI 데이터에 대한 제안 보정 기법을 적용하여 보정 결과를 시각화 한 그림이다. 좌측은 보정하지 않은 원천 데이터(Raw data)이고, 우측은 제안 보정기법을 통해 보정된 시계열 데이터(Corrected Data)를 나타낸다.

2. 이상치 종류에 따른 보정 기법

본 논문은 시계열 데이터의 특성을 고려하기 위해 점 이상치(point anomaly)와 집단적 이상치(collective anomaly)를 구분하여 보정을 진행하였다.

점 이상치는 개별 값이 주변 데이터와 크게 벗어나 있을 때 발생하는 일시적인 이상치이다. 따라서 점 이상치에 대한 보정은 한 윈도우 단위로 진행하며, 점 이상치로부터 주변 윈도우를 기준 윈도우로 삼아 참조 윈도우들을 찾는다. 그림 3.4.4는 점 이상치에 대한 보정 과정을 설명하고 있다. 빨간색 윈도우가 이상 윈도우로 탐지되었다면 1,2 번 윈도우를 기준으로 Window Relevance Matrix가 생성된다. 그리고 윈도우 연관성이 임계값 이상인 윈도우들의 정보를 가지고 보정을 진행한다.




그림 3.4.4 점 이상치에 대한 보정 과정

두 번째로 집단 이상치에 대한 보정 방법이다. 집단 이상치는 여러 데이터 포인트가 모여 집단적으로 비정상적인 패턴을 나타낼 때 발생하는 이상치이다. 따라서, 연속된 윈도우의 수만큼 윈도우들의 그룹 단위로 참조 윈도우들을 찾는다.

이때, 검색 윈도우의 범위가 다른 이상 윈도우 범위와 겹칠 수 있으므로 먼저 점 이상치에 대한 보정을 완료한 후에, 집단 이상치에 대해 보정을 진행한다. 또한 이상 윈도우로부터 뒤의 기준 윈도우들에는 다른 이상 윈도우가 포함될 수 있다. 따라서 집단 이상치에 대해서는 이상 윈도우로부터 앞 윈도우들에 대해서만 기준 윈도우로 삼았다. 그림 3.4.5는 집단 이상치에 대한 보정 과정을 설명하고 있다.

이상 윈도우에 대해 1번 윈도우 그룹을 기준으로 Window Relevance Matrix를 생성한다. 그리고 윈도우 연관성이 임계값 이상인 윈도우들의 정보를 가지고 보정을 진행한다.




그림 3.4.5 집단 이상치에 대한 보정 과정

3. Window Relevance Matrix

본 논문에서는 기준 윈도우와 가장 연관성이 높은 윈도우를 탐색하기 위해 Window Relevance matrix를 생성한다. 이를 위해 DTW와 피어슨 상관계수를 활용하여 두 윈도우 간의 유사성을 측정할 수 있는 Window Relevance를 구성하였다.




그림 3.4.6 한 변수에 대한 DTW 정렬 과정 예시

첫 번째로, DTW는 시계열 데이터 간의 패턴 유사성을 측정하는 알고리즘으로, 시간적 왜곡을 허용하여 다른 속도로 변화하는 데이터 간에도 유사성을 효과적으로 평가한다. 그림 3.4.6는 Target window와 Search window 간의 DTW 정렬 과정에 대한 예시를 시각적으로 나타낸다. 그림과 같이 각 변수에 대해 계산하며, 이후 평균 기반으로 결합된 DTW 값이 최종적으로 반영된다. 이를 통해 단순한 값 비교를 넘어 시계열 데이터에 대한 패턴을 효과적으로 반영할 수 있다. 참고로, DTW 값이 작을수록 유사한 패턴을 가진 것으로 해석된다.

두 번째로, 피어슨 상관 계수는 변수들 간의 선형적 상관관계를 나타내며, -1에서 1 사이의 값을 가진다. 양의 상관 관계가 클수록 1에 가까워지고, 음의 상관 관계가 클수록 -1에 가까워진다. 상관 관계가 없을 경우 값은 0에 수렴한다. 그림 3.4.7은 Target window와 Search window에 대한 상관관계수 행렬 생성 예시이다. 생성된 두 행렬 간의 차이를 통해 두 윈도우의 변수들 간의 관계가 유사한지를 비교할 수 있다. 본 논문에서는 Frobenius Norm을 사용해 두 행렬 간의 거리 $\|w_T - w_S\|_F$ 를 계산하여 유사도를 반영한다. 이 거리가 작을수록 두 윈도우 간

상관관계가 더 유사함을 나타낸다.




그림 3.4.7 피어슨 상관계수 행렬 비교 예시

결과적으로, 본 논문에서는 DTW와 피어슨 상관계수를 결합하여 다음과 같은 공식을 통해 윈도우 연관성을 정의하였다:

$$\begin{aligned} \text{Window Relevance}(w_T, w_S) \\ = \alpha \cdot (1 - N_{DTW}(w_T, w_S)) + \beta \cdot (1 - N_{Pearson}(w_T, w_S)) \end{aligned} \quad (3.4.1)$$

식 3.4.1은 Target window w_T 와 Search window w_S 간의 윈도우 연관성을 계산하는 식이다. 여기서 DTW 값과 Pearson 값의 차이에 대해 minmax 정규화(Normalization)를 수행(N_{DTW} , $N_{Pearson}$)하였으며, 유사성이 높을수록 더 높은 점수를 부여하기 위해 1에서 빼는 방식으로 반영된다. 또한, 가중치 α 와 β 를 통해 패턴 유사성과 변수 간 상관관계 유사성의 중요도를 조절할 수 있도록 설계하였다. 최종적으로 윈도우 연관성은 0에서 1 사이의 값을 가지며, 값이 1에 가까울수록 두 윈도우 간의 연관성이 높다는 것을 의미한다. 본 연구에서는 $\alpha=0.7$ 과 $\beta=0.3$ 으로 설정하였다.

제 4장 실험 방법 및 평가

본 연구는 제안 보정기법을 이용하여 이상값을 정상값으로 보정한 효과를 다변량 시계열 예측모델의 성능 평가를 통해 간접적으로 확인하고자 한다.

제1절 실험 환경

제안 기법의 효능 실험을 위해 SUTD의 iTrust 연구소에서 공개한 SWaT[24]와 WADI[1], 국가보안기술연구소에서 공개한 HAI[13], 그리고 Kaggle의 SKAB 데이터셋을 이용하였다.

- SWaT(Secure Water Treatment) : 물 정화 시스템의 이상 탐지 및 사이버 보안 연구를 위해 설계된 데이터셋이다. 이 데이터는 실제 산업 환경을 소규모로 구현한 테스트베드에서 수집되었으며, 정상 동작 상태와 다양한 사이버 공격 시나리오(센서 데이터 변조, 펌프 오작동 등)를 포함한다. SWAT은 물 정화 과정을 단계별로 구현하며, 유량, 압력, 수위와 같은 센서 데이터를 기반으로 이루어져있다.
- WADI(Water Distribution) : 물 분배 시스템에서 발생할 수 있는 이상 행동과 사이버 공격을 연구하기 위해 설계된 데이터셋이다. 이 데이터는 대규모의 물 분배 네트워크를 모사한 테스트베드에서 수집되었으며, 정상적인 시스템 동작 데이터와 다양한 공격 시나리오(파이프 누수, 데이터 변조, 센서 교란 등)를 포함한다. WADI는 유량, 압력 등의 센서 데이터로 이루어져있다.
- HAI(HIL-based Augmented ICS) : 산업 제어 시스템(ICS)의 사이버 보안과 이상 탐지를 연구하기 위해 개발된 데이터셋이다. 증기 터빈 발전, 수력 저장 같은 공정을 모의한 테스트베드에서 수집되었다. 압력, 유량, 온도 등 산업 환경의 데이터를 제공하며, 다양한 사이버 공격 시나리오를 포함한다.
- SKAB(Skoltech Anomaly Benchmark) : 이상 탐지 모델을 설계하고 평가하기 위해

만들어진 데이터셋으로, 산업 제어 시스템(CPS)에서 발생할 수 있는 이상 행동을 모방한다. 이 데이터셋은 센서 오류, 장비 고장 등 다양한 이상 행동을 포함한다. SKAB은 주로 전압, 유량, 온도 등의 변수를 다룬다.

표 4.1.1은 실험 데이터에 대한 정보를 담고 있다. 우리는 SWaT, WADI, HAI, 데이터셋에 대해서는 기존 변수들 중 변화량이 거의 없는 변수를 제거하여 실험을 진행하였다.

표 4.1.1 실험 데이터 정보

	데이터			
	SWaT	WADI	HAI	SKAB
변수	51	103	78	8
학습 데이터	496,800	1,048,571	921,603	10,897
테스트 데이터	449,919	172,801	402,005	7,265
실험에 사용된 변수	14	27	22	8
이상 비율(%)	11.98	5.99	2.23	34.74

제2절 실험 방법

다변량 시계열 데이터의 보정기법은 주어진 데이터를 사용하여 구축된 예측모델의 성능 평가를 통해 간접적으로 평가되는 것이 일반적이다. 그림 4.2.1은 예측 모델 성능으로 보정에 대한 간접 평가를 하고자 하는 이유에 대해서 설명하는 그림이다. 원천 데이터를 가지고 학습한 모델은 이상치가 포함되어 있기 때문에 예측 모델을 성능을 저하시킬 가능성이 크다. 그에 비해 보정된 데이터를 가지고 학습된 모델은 안정적이고 정확한 예측을 수행할 가능성이 크다. 따라서, 보정된 데이터를 가지고 학습한 모델이 예측 결과의 오차를 줄일 것으로 예상하며 이는 결과적으로 보정의 효과를 입증할 수 있다.




그림 4.2.1 모델 성능으로 인한 간접 평가

본 논문에서는 예측모델의 구축을 위해 LSTM 알고리즘을 사용하였다. 그리고 이상값이 포함된 원천 데이터와 보정된 데이터에 대한 예측모델의 정량적인 평가를 위해 식 4.2.1의 평균 절대오차(MAE)와 식 4.2.2의 평균 제곱근 오차(RMSE)를 이용하며, 이 값이 작을수록 해당 예측모델의 성능이 우수함을 의미한다. 여기서 Y_i 은 실제 수치, $\hat{Y}_i$ 은 예측 수치를 의미한다.

$$MAE = \frac{1}{n} \sum_{i=1}^n |\hat{Y}_i - Y_i|, \quad (4.2.1)$$

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (\hat{Y}_i - Y_i)^2} \quad (4.2.2)$$

제3절 성능 평가

제안 보정기법의 성능을 비교하기 위해 원천 데이터와 이상값을 제거한 데이터 그리고 기존의 보정방법을 통해 보정한 데이터로 예측모델을 구축하였다. 또한 우리는 데이터 보정을 위한 윈도우를 생성할 때 Window Relevance Matrix에 대한 임계값(t_2)에 대해서 윈도우 크기별로 성능을 비교하였다.

표 4.3.1은 SWaT 데이터를 이용하여 보정기법 성능을 비교한 표이다. 윈도우 크기 별 성능 비교 결과, 제안 기법으로 보정된 데이터로 구축한 예측모델의 성능이 가장 우수함을 확인할 수 있다. 표 4.3.2는 WADI 데이터를 이용하여 보정기법 성능을 비교한 표로 SWaT 데이터에 대한 결과와 마찬가지로 제안 기법으로 보정된 데이터로 구축한 예측모델의 성능이 가장 우수함을 확인할 수 있다. 또한 표 4.3.3은 HAI 데이터를 이용하여 보정기법 성능을 비교한 표이며 마지막으로 표 4.3.4는 SKAB 데이터를 이용하여 보정기법 성능을 비교한 표이다. 이전 결과들과 마찬가지로 제안 기법으로 보정된 데이터로 구축한 예측모델의 성능이 가장 우수함을 확인할 수 있다. 우리는 각 데이터셋에 대해서 윈도우 크기를 30, 60, 120로 나누어 성능 평가를 진행하였다.

예측 모델의 성능 비교 결과, 원천 데이터에 비해서는 제안 보정 기법에 대한 성능이 3.5%~12.1% 향상되었으며, 이상값 제외한 데이터에 비해서는 4.6%~10.0%, Kalman 필터링 기반 보정기법에 비해서는 0.3%~15.1%, 평균 기반 보정기법에 비해서는 3.3%~8.7%, SVR 기반 보정 기법에 비해서는 3.6%~17.3%, 그리고 LSTM 기반 보정 기법에 비해서는 0.1%~18.4% 향상된 것을 확인할 수 있다.

표 4.3.1 SWaT 데이터에 대한 보정 기법 성능 비교

윈도우 크기	데이터	MAE	RMSE
30	원천 데이터	0.0466	0.0949
	이상값 제외	0.0473	0.0940
	Kalman 필터링	0.0443	0.0901
	평균 기반 보정	0.0467	0.0921
	SVR 기반 보정	0.0447	0.0908
	LSTM 기반 보정	0.0450	0.0941
	제안 보정	0.0414	0.0854
60	원천 데이터	0.0509	0.1011
	이상값 제외	0.0481	0.0938
	Kalman 필터링	0.0491	0.0931
	평균 기반 보정	0.0647	0.0930
	SVR 기반 보정	0.0486	0.0930
	LSTM 기반 보정	0.0483	0.0920
	제안 보정	0.0467	0.0924
120	원천 데이터	0.0451	0.0949
	이상값 제외	0.0471	0.0941
	Kalman 필터링	0.0445	0.0940
	평균 기반 보정	0.0480	0.0931
	SVR 기반 보정	0.0466	0.0901
	LSTM 기반 보정	0.0450	0.0941
	제안 보정	0.0444	0.0908




그림 4.3.1 SWaT에 대한 보정기법 성능 비교 시각화

표 4.3.2 WADI 데이터에 대한 보정 기법 성능 비교

윈도우 크기	데이터	MAE	RMSE
30	원천 데이터	0.0883	0.1442
	이상값 제외	0.0963	0.1544
	Kalman 필터링	0.0882	0.1430
	평균 기반 보정	0.0925	0.1515
	SVR 기반 보정	0.0949	0.1543
	LSTM 기반 보정	0.0881	0.1440
	제안 보정	0.0880	0.1439
60	원천 데이터	0.0927	0.1444
	이상값 제외	0.0966	0.1539
	Kalman 필터링	0.0864	0.1459
	평균 기반 보정	0.0941	0.1529
	SVR 기반 보정	0.0924	0.1465
	LSTM 기반 보정	0.0920	0.1465
	제안 보정	0.0865	0.1418
120	원천 데이터	0.0991	0.1564
	이상값 제외	0.0920	0.1563
	Kalman 필터링	0.0999	0.1583
	평균 기반 보정	0.0946	0.1518
	SVR 기반 보정	0.0949	0.1549
	LSTM 기반 보정	0.0990	0.1530
	제안 보정	0.0910	0.1504




그림 4.3.2 WADI에 대한 보정기법 성능 비교 시각화

표 4.3.3 HAI 데이터에 대한 보정 기법 성능 비교

윈도우 크기	데이터	MAE	RMSE
30	원천 데이터	0.0510	0.0758
	이상값 제외	0.0508	0.0756
	Kalman 필터링	0.0501	0.0753
	평균 기반 보정	0.0513	0.0758
	SVR 기반 보정	0.0531	0.0866
	LSTM 기반 보정	0.0501	0.0756
	제안 보정	0.0433	0.0755
60	원천 데이터	0.0489	0.0740
	이상값 제외	0.0487	0.0738
	Kalman 필터링	0.0473	0.0739
	평균 기반 보정	0.0496	0.0739
	SVR 기반 보정	0.0519	0.0866
	LSTM 기반 보정	0.0483	0.0865
	제안 보정	0.0432	0.0760
120	원천 데이터	0.0570	0.0850
	이상값 제외	0.0574	0.0739
	Kalman 필터링	0.0398	0.0726
	평균 기반 보정	0.0493	0.0739
	SVR 기반 보정	0.0516	0.0868
	LSTM 기반 보정	0.0515	0.0826
	제안 보정	0.0387	0.0706




그림 4.3.3 HAI에 대한 보정기법 성능 비교 시각화

표 4.3.4 SKAB 데이터에 대한 보정 기법 성능 비교

윈도우 크기	데이터	MAE	RMSE
30	원천 데이터	0.1531	0.1758
	이상값 제외	0.1508	0.1756
	Kalman 필터링	0.1501	0.1756
	평균 기반 보정	0.1513	0.1758
	SVR 기반 보정	0.1531	0.1866
	LSTM 기반 보정	0.1451	0.1757
	제안 보정	0.1433	0.1755
60	원천 데이터	0.1489	0.1740
	이상값 제외	0.1487	0.1738
	Kalman 필터링	0.1481	0.1730
	평균 기반 보정	0.1496	0.1739
	SVR 기반 보정	0.1519	0.1866
	LSTM 기반 보정	0.1478	0.1899
	제안 보정	0.1432	0.1726
120	원천 데이터	0.1570	0.1850
	이상값 제외	0.1574	0.1739
	Kalman 필터링	0.1573	0.1861
	평균 기반 보정	0.1493	0.1739
	SVR 기반 보정	0.1516	0.1868
	LSTM 기반 보정	0.1432	0.1738
	제안 보정	0.1387	0.1706




그림 4.3.4 SKAB에 대한 보정기법 성능 비교 시각화

표 4.3.5는 데이터 보정을 위한 윈도우를 생성할 때 Window Relevance Matrix에 대한 임계값(t_2)에 대해서 윈도우 크기별로 성능을 비교한 것을 나타낸다. 임계값은 상위 0.01%, 0.1%, 1%로 나누어 실험하였다.

SWaT과 WADI 데이터셋에 대해서는 윈도우 크기가 30이고 임계값이 0.01%인 경우 가장 좋은 성능을 보였으며 HAI 데이터셋에 대해서는 윈도우 크기가 120이고 임계값이 0.01%인 경우 가장 좋은 성능을 보였다. 마지막으로 SKAB 데이터셋에 대해서는 윈도우 크기가 120이고 임계값이 1%인 경우 가장 좋은 성능을 보였다.

표 4.3.5 Window Relevance 임계값에 따른 성능 비교

윈도우 크기	데이터	MAE			RMSE		
		0.01%	0.1%	1%	0.01%	0.1%	1%
30	SWaT	0.0414	0.0415	0.0516	0.0854	0.0852	0.0857
	WADI	0.0881	0.0880	0.0886	0.1459	0.1439	0.1443
	HAI	0.0435	0.0433	0.0551	0.0820	0.0755	0.0752
	SKAB	0.1443	0.1453	0.1433	0.1757	0.1766	0.1755
60	SWaT	0.0467	0.0468	0.0469	0.0924	0.0925	0.0931
	WADI	0.0867	0.0865	0.0867	0.1459	0.1418	0.1428
	HAI	0.0438	0.0432	0.0511	0.0771	0.0760	0.0780
	SKAB	0.1432	0.1433	0.1432	0.1727	0.1728	0.1726
120	SWaT	0.0445	0.0444	0.0478	0.0911	0.0908	0.0921
	WADI	0.0910	0.0912	0.0913	0.1504	0.1502	0.1501
	HAI	0.0387	0.0389	0.0412	0.0706	0.0710	0.0712
	SKAB	0.1401	0.1389	0.1387	0.1711	0.1701	0.1706

그림 4.3.1, 4.3.2, 4.3.3, 4.3.4는 각 데이터에 대해 예측모델을 적용하고 예측값과 실제값에 대한 잔차를 비교한 그래프이다. 이는 예측 값과 실제 값 간의 차이를 의미한다. 이를 통해, 원천 데이터로 예측 모델을 구축하였을 때 보다 제안된 보정 기법으로 예측 모델을 구축하였을 때 예측 값과 실제 값 간의 차이가 더 작은 것을 확인 할 수 있다.




그림 4.3.5 SWaT 데이터에 대한 예측모델 잔차 비교




그림 4.3.6 WADI 데이터에 대한 예측모델 잔차 비교




그림 3.4.7 HAI 데이터에 대한 예측모델 잔차 비교




그림 4.3.8 SKAB 데이터에 대한 예측모델 잔차 비교

제 5장 결론

본 논문은 다변량 시계열 데이터 품질 개선을 위해 LSTM 기반 VAE-GAN 이상탐지 모델을 이용한 보정기법을 제안하였다. 이는 기존의 보정기법들과 달리 이상탐지와 보정을 한 번의 학습만으로 동시에 수행할 수 있다는 장점이 있다. 제안 기법의 우수성을 보이기 위해 예측모델 구축을 통해 간접적으로 비교한 결과, 제안 보정기법을 통해 품질이 개선된 데이터로 구축한 예측모델의 성능이 기존 보정기법에 비해 뛰어난 성능을 보였음을 확인하였다. 또한 데이터 내에 존재하는 이상값을 보정하지 않고 제거한 데이터와 비교했을 때 성능이 더 우수함을 확인하였다. 이는 다변량 시계열 데이터의 특성을 반영하여 이상값들을 보정함으로써 데이터의 품질을 개선하고 신뢰성 있는 인공지능 모델을 구축에 기여할 수 있다는 가능성을 보였다.

본 논문에서는 VAE-GAN 모델을 학습시킬 때 이상값에 대한 레이블이 있는 벤치마크 데이터셋을 이용하여 학습을 진행하였다. 이때 정상값을 가진 데이터만을 가지고 학습을 진행하게 된다. 하지만 실제 데이터에서는 이상값이 포함되어 있으며 이상에 대한 레이블이 되어있지 않은 경우가 더 많은 것을 볼 수 있다. 따라서 향후 연구에서는 이상에 대한 레이블이 없는 데이터 즉, 실제 데이터들에 대한 이상 탐지 및 보정에 대한 성능 향상을 목표로 하여 보정 기법을 개발할 예정이다.

참 고 문 헌

- [1] Ahmed, C. M., Palleti, V. R., & Mathur, A. P., 2017, "WADI: a water distribution testbed for research in the design of secure cyber-physical systems," Proceedings of the 3rd International Workshop on Cyber-Physical Systems for Smart Water Networks, ACM, pp. 25-28.
- [2] Ahn, H., Sun, K., & Kim, K. P., 2022, "Comparison of missing data imputation methods in time series forecasting," Computers, vol. 11, no. 2, pp. 24-34.
- [3] Baghoussi, Yassine, Carlos Soares, and João Mendes-Moreira. "Corrector LSTM: built-in training data correction for improved time-series forecasting." Neural Computing and Applications (2024): 1-19.
- [4] Chandola, V., Banerjee, A., & Kumar, V., 2009, "Anomaly detection: A survey," ACM Computing Surveys (CSUR), vol. 41, no. 3, pp. 1-58.
- [5] Chen, Z., et al., 2018, "Autoencoder-based network anomaly detection," 2018 Wireless Telecommunications Symposium (WTS), IEEE, pp. 45-50.
- [6] Choi, J., & Shin, Y., 2021, "Design of efficient big data collection method based on mass IoT devices," J. Korea Inst. Inf. Electron. Commun. Technol., vol. 14, no. 4, pp. 300-306.
- [7] Deng, A., & Hooi, B., 2021, "Graph neural network-based anomaly detection in multivariate time series," Proceedings of the AAAI Conference on Artificial Intelligence, vol. 35, no. 5, pp. 4561-4568.
- [8] Ergen, T., & Kozat, S. S., 2019, "Unsupervised anomaly detection with LSTM neural networks," IEEE Transactions on Neural Networks and Learning Systems, vol. 31, no. 8, pp. 3127-3141.
- [9] Ester, M., Kriegel, H. P., Sander, J., & Xu, X., 1996, "A density-based algorithm for discovering clusters in large spatial databases with noise," Proceedings of the Second International Conference on Knowledge Discovery

and Data Mining (KDD-96), pp. 226-231.

- [10] Ge, M., Bangui, H., & Buhnova, B., 2018, "Big Data for Internet of Things: A Survey," *Future Gener. Comput. Syst.*, vol. 87, pp. 601-614.
- [11] Goodfellow, I., et al., 2020, "Generative adversarial networks," *Communications of the ACM*, vol. 63, no. 11, pp. 139-144.
- [12] Granger, Clive WJ, and Andrew A. Weiss. "Time series analysis of error-correction models." *Studies in econometrics, time series, and multivariate statistics*. Academic Press, 1983. 255-278.
- [13] H.-K. Shin, W. Lee, J.-H. Yun, and B.-G. Min, 'Two ICS Security Datasets and Anomaly Detection Contest on the HIL-based Augmented ICS Testbed', in *Cyber Security Experimentation and Test Workshop, Virtual CA USA: ACM*, Aug. 2021, pp. 36-40.
- [14] Iglewicz, B., & Hoaglin, D. C., 1993, *How to detect and handle outliers*, ASQC Quality Press, Milwaukee.
- [15] Kim, J., & Lee, S., 2020, "Predictive maintenance of manufacturing equipment through time-series data analysis," *Journal of Manufacturing Systems*, vol. 56, pp. 201-210.
- [16] Kim, J., & Lee, S., 2022, "Anomaly Detection in Time-Series Data: A Survey," *IEEE Access*, vol. 10, pp. 12345-12356.
- [17] Kim, T., & Park, J., 2023, "Image Segmentation for Fire Prediction using Deep Learning," *The Journal of The Institute of Internet, Broadcasting and Communication*, vol. 23, no. 1, pp. 65-70.
- [18] Knorn, F., & Leith, D. J., 2008, "Adaptive Kalman filtering for anomaly detection in software appliances," *IEEE INFOCOM Workshops 2008*, IEEE, pp. 245-250.
- [19] Lee, H., et al., 2020, "Anomaly Detection Using Advanced Neural Networks," *Neural Comput. Appl.*, vol. 32, pp. 123-136.
- [20] Lee, I., & Lee, K., 2015, "The Internet of Things (IoT): Applications,

- investments, and challenges for enterprises," *Business Horizons*, vol. 58, no. 4, pp. 431-440.
- [21] Lee, M.-K., Moon, S.-H., Kim, Y.-H., & Moon, B.-R., 2014, "Correcting abnormalities in meteorological data by machine learning," 2014 IEEE International Conference on Systems, Man, and Cybernetics (SMC), IEEE, pp. 888-893.
- [22] Lu, W., & Ghorbani, A. A., 2009, "Network anomaly detection based on wavelet analysis," *EURASIP Journal on Advances in Signal Processing*, vol. 2009, pp. 1-16.
- [23] Mao, W., Wang, W., Dou, Z., & Li, Y., 2018, "Fire recognition based on multi-channel convolutional neural network," *Fire Technology*, vol. 54, no. 3, pp. 809-809.
- [24] Mathur, A. P., & Tippenhauer, N. O., 2016, "SWaT: a water treatment testbed for research and training on ICS security," 2016 International Workshop on Cyber-Physical Systems for Smart Water Networks (CySWater), Vienna, IEEE, pp. 31-36.
- [25] Nakano, M., Takahashi, A., & Takahashi, S., 2017, "Generalized exponential moving average (EMA) model with particle filtering and anomaly detection," *Expert Systems with Applications*, vol. 73, pp. 187-200.
- [26] Niu, Z., Yu, K., & Wu, X., 2020, "LSTM-based VAE-GAN for time-series anomaly detection," *Sensors*, vol. 20, no. 13, pp. 3738-3746.
- [27] Park, H., & Choi, K., 2021, "Sensor fault detection in IoT systems using time-series analysis," *Sensors*, vol. 21, no. 5, pp. 1234-1245.
- [28] Patel, S., Agarwal, K., & Singh, P., 2021, "An evaluation of anomaly detection and diagnosis in multivariate time series," *IEEE Access*, vol. 9, pp. 4521-4532.
- [29] Ramaswamy, S., Rastogi, R., & Shim, K., 2000, "Efficient algorithms for mining outliers from large data sets," *Proceedings of the 2000 ACM*

- SIGMOD International Conference on Management of Data, pp. 427-438.
- [30] Ren, S., Kim, J. S., Cho, W. S., Soeng, S., & Lee, K. H., 2021, "Big data platform for intelligence industrial IoT sensor monitoring system based on edge computing and AI," 2021 International Conference on Artificial Intelligence in Information and Communication (ICAIIIC), pp. 38-43.
 - [31] Seba, A. M., Gameda, K. A., & Ramulu, P. J., 2024, "Prediction and classification of IoT sensor faults using hybrid deep learning model," Discover Applied Sciences, vol. 6, no. 9, pp. 45-60.
 - [32] Teng, C. M., 2004a, "Polishing blemishes: Issues in data correction," IEEE Intell. Syst., vol. 19, no. 2, pp. 34-39.
 - [33] Teng, C. M., 2004b, "Anomaly Handling in Large Datasets," IEEE Transactions on Data Science, vol. 22, no. 3, pp. 123-136.
 - [34] Xia, X., et al., 2022, "GAN-based anomaly detection: A review," Neurocomputing, vol. 493, pp. 497-535.
 - [35] Yaacob, A. H., et al., 2010, "ARIMA based network anomaly detection," 2010 Second International Conference on Communication Software and Networks, IEEE.
 - [36] Zhang, Jianye, and Peng Yin. "Multivariate time series missing data imputation using recurrent denoising autoencoder." 2019 IEEE International Conference on Bioinformatics and Biomedicine (BIBM). IEEE, 2019.
 - [37] Zhanwei, S., & Zenghui, L., 2019, "Abnormal detection method of industrial control system based on behavior model," Comput. Secur., vol. 84, pp. 166-178.

Abstract

A GAN-Based Multivariate Time Series Data Correction Method Using Window Relevance

SoHyeon Yun

School of Electrical & Computer Eng.

Graduate School of the Univ. of Seoul

Supervised by Prof. Han-joon Kim, Ph. D.

This study proposes a novel data correction method to improve the quality of multivariate time-series data using a GAN-based anomaly detection model. With the recent advancements in IoT technology, there has been a growing trend of leveraging time-series data collected from sensors for quality management and predictive maintenance using deep learning-based models. Time-series data are essential in various industries, including manufacturing, finance, and energy. However, anomalies can arise during data collection and processing due to various factors, leading to degraded data quality and reduced reliability in decision-making. To ensure the reliability and quality of data and enhance the performance of deep learning-based models, data correction for time-series data is crucial. We propose a correction method that combines a deep learning-based anomaly detection model with a Window Relevance Matrix. The proposed method employs an Autoencoder-based GAN model to detect anomalies in time-series data and conducts sophisticated corrections by reflecting the correlations in multivariate time-series data. In particular, the Dynamic Time Warping (DTW) and Pearson correlation coefficients are integrated to generate a Window Relevance Matrix, effectively capturing the complex structures of multivariate time-series data. Experiments conducted on various datasets validate the effectiveness of the proposed method, showing significant improvements in predictive performance compared to raw data. This study introduces a data correction method using an Autoencoder-based GAN model to

enhance data quality, with potential applications in various fields requiring anomaly detection and data refinement.

Keywords: Multivariate Time-Series Data, Anomaly Detection, Data Correction, Correlation, Deep Learning, GAN